

Лабораторна робота №1.

Лінійна регресія та регуляризація на цінах житла

25 серпня 2026 р.

Мета

Побудувати повний регресійний конвеєр на наборі Ames Housing — 1460 будинків, 80 ознак, серед яких 43 категоріальні й 19 стовпців із пропусками — та показати числами, чим відрізняються аналітичний і ітеративний розв’язки, як витік даних завищує оцінку якості й що робить з коефіцієнтами регуляризація.

Теоретичні відомості

Лінійна регресія передбачає неперервну величину як зважену суму ознак: $\hat{y} = \mathbf{x}^\top \mathbf{w} + w_0$. Ваги підбирають мінімізацією середньоквадратичних втрат $\mathcal{L}(\mathbf{w}) = \frac{1}{2N} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2$. На цих даних одразу видно, що модель — найпростіша частина роботи: більшість зусиль піде на підготовку ознак.

- **Два способи знайти ваги.** Нормальні рівняння $\mathbf{w} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ дають точну відповідь за один крок, але псуються, коли ознаки майже лінійно залежні — а після кодування 43 категорій таких пар буде багато. Градієнтний спуск ітеративний і потребує підбору темпу навчання η та стандартизованих ознак.
- **Підготовка ознак.** Числові й категоріальні стовпці вимагають різного поводження, а пропуски бувають двох різних типів: випадкові (не виміряли довжину фасаду) і змістовні (PoolQC порожній, бо басейну немає). Друге — це не пропуск, а окрема категорія, і заповнювати його медіаною було б помилкою.
- **Асиметрія цільової змінної.** Ціни житла скошені вправо: кілька дуже дорогих будинків тягнуть за собою всю шкалу. Логарифмування вирівнює розподіл і робить помилку відносною, а не абсолютною — модель перестає «купувати» точність на дорогих будинках ціною дешевих.

- **Регуляризація.** Ridge додає $\lambda \|\mathbf{w}\|_2^2$ і стискає всі ваги плавно, lasso додає $\lambda \|\mathbf{w}\|_1$ і занулює частину коефіцієнтів, виконуючи відбір ознак. На даних із сотнями стовпців після кодування різниця між ними стає наочною.
- **Витік даних (data leakage).** Якщо масштабування, заповнення пропусків або кодування виконано до розбиття вибірки, інформація про тест потрапляє в модель, і оцінка стає систематично оптимістичною. Лікується збиранням усіх перетворень у `Pipeline`.

Корисні посилання для ознайомлення:

- [Ames Housing на OpenML](#) — сам набір; вантажиться одним викликом `fetch_openml(data_id=42165)`;
- [De Cock D. Ames, Iowa: Alternative to the Boston Housing Data Set](#) — стаття, у якій набір запропоновано, з описом кожної ознаки;
- [scikit-learn: Pipelines and composite estimators](#) — `ColumnTransformer` для змішаних типів даних;
- [Common pitfalls and recommended practices](#) — розділ про витік даних;
- [Hastie T. та ін. The Elements of Statistical Learning](#) — розділ 3; книга доступна безкоштовно на сайті авторів.

Порядок виконання

1. Створити віртуальне оточення та встановити `numpy`, `pandas`, `scikit-learn`, `matplotlib`. Зафіксувати `random_state=0` у всіх викликах, де він передбачений.
2. Завантажити набір: `fetch_openml(data_id=42165, as_frame=True)`. Підтвердити розміри (1460 рядків, 81 стовпець разом із ціною) і розділити ознаки на числові та категоріальні. Навести таблицю описових статистик числових ознак і десять найчастіших значень трьох категоріальних.
3. Дослідити пропуски: побудувати графік кількості пропусків за стовпцями. Для трьох стовпців із найбільшою часткою пропусків подивитися в опис набору й вирішити, який з них означає «ознаки немає», а який — «не виміряли». Обґрунтувати різну стратегію заповнення для цих двох випадків.
4. Побудувати гістограму `SalePrice` та її логарифма, навести коефіцієнт асиметрії для обох. Далі працювати з логарифмом ціни; пояснити, як це змінює зміст помилки моделі.

5. Відкласти 20 % даних як тестову вибірку і не звертатися до неї до останнього пункту. Зібрати `ColumnTransformer`: для числових — заповнення медіаною та стандартизація, для категоріальних — заповнення константою й `OneHotEncoder(handle_unknown="ignore")`. Навести, скільки стовпців стало після кодування.
6. Розв'язати задачу найменших квадратів двома способами: власноруч через `np.linalg.lstsq` і бібліотечним `LinearRegression` на тих самих закодованих ознаках. Звірити ваги, навести максимальну розбіжність і число обумовленості матриці $\mathbf{X}^\top \mathbf{X}$.
7. Реалізувати пакетний градієнтний спуск для середньоквадратичних втрат. Прогнати щонайменше чотири значення темпу навчання на стандартизованих ознаках, побудувати криві втрат і показати, за якого η спуск розбігається.
8. Виміряти витік даних: порівняти на тих самих фолдах дві процедури — (а) усі перетворення виконано один раз на всіх тренувальних даних до крос-валідації; (б) ті самі перетворення зібрано в `Pipeline`. Навести обидві оцінки RMSE і пояснити знак розбіжності.
9. Побудувати криві валідації для `Ridge` і `Lasso` щонайменше на 8 значеннях λ в логарифмічній сітці. Для найкращої моделі кожного типу навести кількість ненульових коефіцієнтів і десять ознак із найбільшими за модулем вагами.
10. Для обраної моделі побудувати на тестовій вибірці три графіки: прогноз проти факту, залишок проти прогнозу та гістограму залишків. Знайти три будинки з найбільшою помилкою й подивитися на їхні ознаки: що саме модель не змогла врахувати.
11. Звести тестові метрики всіх моделей у таблицю (RMSE в логарифмі та в доларах, R^2). Зробити висновки: яка модель обрана, чому, і які обмеження вона має на цих даних.

Контрольні запитання

1. Чому після кодування категорій матриця $\mathbf{X}^\top \mathbf{X}$ стає погано обумовленою? Що саме з цим робить `ridge`-регресія?
2. Пропуск у стовпці `PoolQC` і пропуск у стовпці `LotFrontage` мають різну природу. Як це впливає на вибір стратегії заповнення?
3. Що змінює логарифмування цільової змінної в тому, які помилки модель вважає великими?
4. Чому `lasso` занулює коефіцієнти, а `ridge` — ні? Достатньо геометричного пояснення.

5. Що конкретно псує кодування категорій, виконане до розбиття на фолди, і чому знак похибки оцінки завжди один і той самий?
6. Ви отримали RMSE 0,13 у логарифмі ціни. Що це число означає в доларах для будинку за 150 тисяч і для будинку за 500 тисяч?