

Лабораторна робота №1.

Лінійна регресія, градієнтний спуск та регуляризація

25 серпня 2026 р.

Мета

Побудувати повний регресійний конвеєр на реальному наборі California Housing — від розвідувального аналізу до чесно оціненої регуляризованої моделі — та показати числами, чим відрізняються аналітичний і ітеративний розв’язки, як витік даних завищує оцінку якості й що робить з коефіцієнтами регуляризація.

Теоретичні відомості

Лінійна регресія передбачає неперервну величину як зважену суму ознак: $\hat{y} = \mathbf{x}^\top \mathbf{w} + w_0$. Ваги підбирають мінімізацією середньоквадратичних втрат $\mathcal{L}(\mathbf{w}) = \frac{1}{2N} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2$. Попри простоту, саме на цій моделі зручно вперше побачити всі складові практичної роботи: підготовку даних, вибір гіперпараметрів, чесний протокол оцінювання та діагностику помилок.

- **Два способи знайти ваги.** Нормальні рівняння $\mathbf{w} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ дають точну відповідь за один крок, але вимагають обертання матриці розміру $D \times D$ і псуються, коли ознаки майже лінійно залежні. Градієнтний спуск ітеративний, масштабується на великі вибірки, проте потребує підбору темпу навчання η та стандартизованих ознак.
- **Регуляризація.** Штраф за складність додається до втрат: ridge додає $\lambda \|\mathbf{w}\|_2^2$ і стискає всі ваги плавно, lasso додає $\lambda \|\mathbf{w}\|_1$ і занулює частину коефіцієнтів повністю, виконуючи відбір ознак. Параметр λ підбирають на валідації, а не за тренувальною помилкою.
- **Витік даних (data leakage).** Якщо масштабування або відбір ознак виконано до розбиття вибірки, інформація про тест потрапляє в модель, і оцінка якості стає систематично оптимістичною. Лікується збиранням усіх перетворень у Pipeline і передаванням у крос-валідацію саме конвеєра.

- **Діагностика залишків.** Агрегована метрика приховує структуру помилок. Графік «залишок проти прогнозу» виявляє нелінійність, гетероскедастичність і цензуровану цільову змінну — те, чого не видно ані в R^2 , ані в RMSE.

Корисні посилання для ознайомлення:

- [scikit-learn User Guide: Linear Models](#) — документація з усіма варіантами регуляризації;
- [Common pitfalls and recommended practices](#) — розділ про витік даних і правильне користування конвеєрами;
- [Hastie T., Tibshirani R., Friedman J. The Elements of Statistical Learning](#) — розділ 3; книга доступна безкоштовно на сайті авторів;
- [Common pitfalls in the interpretation of coefficients of linear models](#) — чому коефіцієнти не можна читати як «важливість ознаки».

Порядок виконання

1. Створити віртуальне оточення та встановити `numpy`, `pandas`, `scikit-learn`, `matplotlib`. Зафіксувати `random_state=0` у всіх викликах, де він передбачений: усі наведені далі числа мають відтворюватися.
2. Завантажити набір California Housing (`fetch_california_housing`): 20 640 округів перепису США 1990 року, 8 числових ознак, цільова змінна — медіанна вартість житла в сотнях тисяч доларів. Навести таблицю описових статистик і кореляційну матрицю ознак.
3. Перевірити цільову змінну на цензурування: підрахувати, скільки округів мають `MedHouseVal` рівно 5.00001, і виразити їхню частку у відсотках. Пояснити, як ця особливість вплине на залишки моделі.
4. Відкласти 20 % даних як тестову вибірку (`train_test_split`) і не звертатися до неї до останнього пункту. Усі рішення — вибір моделі, гіперпараметрів, перетворень — приймати за крос-валідацією на решті даних.
5. Розв'язати задачу найменших квадратів двома способами: власноруч через `np.linalg.solve` для нормальних рівнянь і через `np.linalg.lstsq`. Звірити отримані ваги з `LinearRegression` і навести максимальну розбіжність.
6. Реалізувати пакетний градієнтний спуск для середньоквадратичних втрат. Прогнати щонайменше чотири значення темпу навчання (наприклад, 10^{-8} , 10^{-3} , 10^{-2} , 10^{-1}) на стандартизованих ознаках і побудувати криві втрат. Показати, за якого η спуск розбігається.

7. Виміряти витік даних: порівняти на тих самих фолдах дві процедури — (а) **StandardScaler** навчено один раз на всіх тренувальних даних до крос-валідації; (б) масштабування зібрано в **Pipeline** разом із моделлю. Навести обидві оцінки RMSE і пояснити знак розбіжності.
8. Побудувати криві валідації для **Ridge** і **Lasso** щонайменше на 8 значеннях λ в логарифмічній сітці. Для найкращої моделі кожного типу навести кількість ненульових коефіцієнтів і порівняти набори відібраних ознак.
9. Для обраної моделі побудувати три графіки на тестовій вибірці: залишок проти прогнозу, гістограму залишків і криву навчання (помилка від розміру тренувальної вибірки). Пояснити, що видно на кожному.
10. Звести тестові метрики всіх моделей (МНК, ridge, lasso) в одну таблицю з однаковою кількістю знаків після коми. Зробити висновки: яка модель обрана, чому, і які обмеження вона має на цих даних.

Контрольні запитання

1. За яких умов матриця $\mathbf{X}^\top \mathbf{X}$ стає необоротною або погано обумовленою? Що саме з цим робить ridge-регресія?
2. Градієнтний спуск на нестандартизованих ознаках розбігається при темпі навчання, який на стандартизованих збігається. Що саме змінила стандартизація?
3. Чому lasso занулює коефіцієнти, а ridge — ні? Достатньо геометричного пояснення через форму області обмежень.
4. Чому значення λ не можна обирати за тренувальною помилкою? Чому його не можна обирати й за тестовою?
5. Що конкретно псує масштабування, виконане до розбиття на фолди, і чому знак похибки оцінки завжди один і той самий?
6. Цільова змінна обрізана згори. Які показники якості це приховують, а які — виявляють?