

Лабораторна робота №1.

Лінійна регресія та регуляризація на цінах житла

2 вересня 2026 р.

Мета

Побудувати повний регресійний конвеєр на наборі Ames Housing — реальних даних про продаж житла з категоріальними ознаками та пропусками різної природи — і показати числами, чим відрізняються аналітичний і ітеративний розв’язки, як витік даних завищує оцінку якості й що робить з коефіцієнтами регуляризація.

Теоретичні відомості

Лінійна регресія передбачає неперервну величину як зважену суму ознак: $\hat{y} = \mathbf{x}^\top \mathbf{w} + w_0$. Ваги підбирають мінімізацією середньоквадратичних втрат $\mathcal{L}(\mathbf{w}) = \frac{1}{2N} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2$. На цих даних одразу видно, що модель — найпростіша частина роботи: більшість зусиль піде на підготовку ознак.

- **Два способи знайти ваги.** Нормальні рівняння $\mathbf{w} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ дають точну відповідь за один крок, але псуються, коли ознаки майже лінійно залежні — а після кодування 43 категорій таких пар буде багато. Градієнтний спуск ітеративний і потребує підбору темпу навчання η та стандартизованих ознак.
- **Підготовка ознак.** Числові й категоріальні стовпці вимагають різного поводження, а пропуски бувають двох різних типів: випадкові (не виміряли довжину фасаду) і змістовні (PoolQC порожній, бо басейну немає). Друге — це не пропуск, а окрема категорія, і заповнювати його медіаною було б помилкою.
- **Асиметрія цільової змінної.** Ціни житла скошені вправо: кілька дуже дорогих будинків тягнуть за собою всю шкалу. Логарифмування вирівнює розподіл і робить помилку відносною, а не абсолютною — модель перестає «купувати» точність на дорогих будинках ціною дешевих.
- **Регуляризація.** Ridge додає $\lambda \|\mathbf{w}\|_2^2$ і стискає всі ваги плавно, lasso додає $\lambda \|\mathbf{w}\|_1$ і занулює частину коефіцієнтів, виконуючи відбір ознак. На даних із сотнями стовпців після кодування різниця між ними стає наочною.
- **Витік даних (data leakage).** Якщо масштабування, заповнення пропусків або кодування виконано до розбиття вибірки, інформація про тест потрапляє в модель, і оцінка стає систематично оптимістичною. Лікується збиранням усіх перетворень у Pipeline.

Корисні посилання для ознайомлення:

- [Ames Housing на OpenML](#) — сам набір; вантажиться викликом `fetch_openml(data_id=42165)`;

- [De Cock D. Ames, Iowa: Alternative to the Boston Housing Data Set](#) — стаття, у якій набір запропоновано, з описом кожної ознаки;
- [scikit-learn: Pipelines and composite estimators](#) — `ColumnTransformer` для змішаних типів даних;
- [Common pitfalls and recommended practices](#) — розділ про витік даних;
- [Hastie T. та ін. The Elements of Statistical Learning](#) — розділ 3; повний текст на сайті авторів.

Порядок виконання

1. Завантажити Ames Housing з OpenML і провести первинний огляд: типи ознак, описові статистики, пропуски. Результат огляду навести у звіті.
2. Показати, що пропуски в цьому наборі мають різну природу, і обґрунтувати різні стратегії їх заповнення.
3. Дослідити розподіл цільової змінної й вирішити, чи потрібне перетворення шкали. Рішення обґрунтувати числом і графіком.
4. Відкласти 20 % даних як тестову вибірку до кінця роботи. Зібрати конвеєр підготовки ознак і виміряти, наскільки завищує оцінку якості витік даних через препроцесинг поза конвеєром.
5. Знайти ваги лінійної моделі аналітично й ітеративно. Довести збіг обох розв’язків числом і показати, за якого темпу навчання градієнтний спуск розбігається (щонайменше чотири значення).
6. Підібрати силу регуляризації для ridge і lasso щонайменше на восьми значеннях у логарифмічній сітці. Показати, чим відрізняються отримані набори ознак.
7. Продіагностувати обрану модель на тестовій вибірці графіками залишків і знайти спостереження з найбільшою помилкою. Пояснити, чого модель не врахувала.
8. Звести метрики всіх моделей в одну таблицю та зробити висновок: яка модель обрана, чому і які має обмеження.

Контрольні запитання

1. Чому після кодування категорій матриця $\mathbf{X}^T \mathbf{X}$ стає погано обумовленою? Що саме з цим робить ridge-регресія?
2. Пропуск у стовпці `PoolQC` і пропуск у стовпці `LotFrontage` мають різну природу. Як це впливає на вибір стратегії заповнення?
3. Що змінює логарифмування цільової змінної в тому, які помилки модель вважає великими?
4. Чому lasso занулює коефіцієнти, а ridge — ні? Достатньо геометричного пояснення.
5. Що конкретно псує кодування категорій, виконане до розбиття на фолди, і чому знак похибки оцінки завжди один і той самий?
6. Ви отримали RMSE 0,13 у логарифмі ціни. Що це число означає в доларах для будинку за 150 тисяч і для будинку за 500 тисяч?