

Лабораторна робота №1.

Лінійна регресія та регуляризація на цінах житла

4 вересня 2026 р.

Мета

Побудувати повний регресійний конвеєр на реальних даних про продаж житла й показати числами, чим відрізняються аналітичний і ітеративний розв’язки, як витік даних завищує оцінку якості й що робить з коефіцієнтами регуляризація. Робота йде на двох наборах: Ames Housing дає категоріальні ознаки та пропуски різної природи, King County — дату кожного продажу, а разом із нею питання, яке на випадковому розбитті просто не виникає: чи вміє модель передбачати майбутнє, а не лише заповнювати прогалини в минулому.

Теоретичні відомості

Лінійна регресія передбачає неперервну величину як зважену суму ознак: $\hat{y} = \mathbf{x}^\top \mathbf{w} + w_0$. Ваги підбирають мінімізацією середньоквадратичних втрат $\mathcal{L}(\mathbf{w}) = \frac{1}{2N} \|\mathbf{y} - \mathbf{X}\mathbf{w}\|_2^2$. На цих даних одразу видно, що модель — найпростіша частина роботи: більшість зусиль піде на підготовку ознак.

- **Два способи знайти ваги.** Нормальні рівняння $\mathbf{w} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$ дають точну відповідь за один крок, але псуються, коли ознаки майже лінійно залежні — а після кодування 43 категорій таких пар буде багато. Градієнтний спуск ітеративний і потребує підбору темпу навчання η та стандартизованих ознак.
- **Підготовка ознак.** Числові й категоріальні стовпці вимагають різного поводження, а пропуски бувають двох різних типів: випадкові (не виміряли довжину фасаду) і змістовні (PoolQC порожній, бо басейну немає). Друге — це не пропуск, а окрема категорія, і заповнювати його медіаною було б помилкою.
- **Асиметрія цільової змінної.** Ціни житла скошені вправо: кілька дуже дорогих будинків тягнуть за собою всю шкалу. Логарифмування вирівнює розподіл і робить помилку відносною, а не абсолютною — модель перестає «купувати» точність на дорогих будинках ціною дешевих.
- **Регуляризація.** Ridge додає $\lambda \|\mathbf{w}\|_2^2$ і стискає всі ваги плавно, lasso додає $\lambda \|\mathbf{w}\|_1$ і занулює частину коефіцієнтів, виконуючи відбір ознак. На даних із сотнями стовпців після кодування різниця між ними стає наочною.
- **Витік даних (data leakage).** Якщо масштабування, заповнення пропусків або кодування виконано до розбиття вибірки, інформація про тест потрапляє в модель, і оцінка стає систематично оптимістичною. Лікується збиранням усіх перетворень у Pipeline.
- **Часова структура даних.** Випадкове розбиття припускає, що спостереження незалежні й однаково розподілені. Для продажів житла це не так: у навчальну частину потрапляють угоди, укладені *пізніше* за тестові, і модель дізнається про стан ринку, якого в момент прогнозу

ще не існувало. Чесна перевірка розбиває вибірку за датою: навчання на ранньому періоді, перевірка на пізньому. Різницю між двома оцінками треба виміряти, а не приймати на віру, — і подивитися, чи однакова вона для жорсткої та для гнучкої моделі.

Корисні посилання для ознайомлення:

- [Ames Housing на OpenML](#) — сам набір; вантажиться викликом `fetch_openml(data_id=42165)`;
- [King County House Sales на OpenML](#) — продажі житла в окрузі Кінг (Сіетл) за рік із хвостиком; вантажиться викликом `fetch_openml(data_id=42092)`, стовпець `date` містить дату угоди;
- [scikit-learn: TimeSeriesSplit](#) — перехресна перевірка, яка не дозволяє навчатися на майбутньому;
- [De Cock D. Ames, Iowa: Alternative to the Boston Housing Data Set](#) — стаття, у якій набір запропоновано, з описом кожної ознаки;
- [scikit-learn: Pipelines and composite estimators](#) — `ColumnTransformer` для змішаних типів даних;
- [Common pitfalls and recommended practices](#) — розділ про витік даних;
- [Hastie T. та ін. The Elements of Statistical Learning](#) — розділ 3; повний текст на сайті авторів.

Порядок виконання

1. Завантажити обидва набори з OpenML і провести первинний огляд: типи ознак, описові статистики, пропуски, часовий діапазон угод. Результат огляду навести у звіті.
2. Показати, що пропуски в Ames Housing мають різну природу, і обґрунтувати різні стратегії їх заповнення. Виміряти, наскільки завищує оцінку якості заповнення, виконане до розбиття вибірки, а не всередині конвеєра.
3. Дослідити розподіл цільової змінної й вирішити, чи потрібне перетворення шкали. Рішення обґрунтувати числом і графіком.
4. Відкласти тестову вибірку до кінця роботи, розбивши дані за датою угоди, а не випадково. Виміряти, наскільки завищує оцінку випадкове розбиття, і перевірити, чи однаковий цей розрив для лінійної моделі та для гнучкішої.
5. Знайти ваги лінійної моделі аналітично й ітеративно. Довести збіг обох розв'язків числом і показати, за якого темпу навчання градієнтний спуск розбігається (щонайменше чотири значення).
6. Підібрати силу регуляризації для `ridge` і `lasso` щонайменше на восьми значеннях у логарифмічній сітці. Показати, чим відрізняються отримані набори ознак.
7. Продіагностувати обрану модель на тестовій вибірці графіками залишків і знайти спостереження з найбільшою помилкою. Пояснити, чого модель не врахувала.
8. Звести метрики всіх моделей і обох наборів в одну таблицю, вказавши для кожного рядка спосіб розбиття. Зробити висновок: яка модель обрана, чому і які має обмеження.

Контрольні запитання

1. Чому після кодування категорій матриця $\mathbf{X}^T \mathbf{X}$ стає погано обумовленою? Що саме з цим робить ridge-регресія?
2. Пропуск у стовпці PoolQC і пропуск у стовпці LotFrontage мають різну природу. Як це впливає на вибір стратегії заповнення?
3. Що змінює логарифмування цільової змінної в тому, які помилки модель вважає великими?
4. Чому lasso занулює коефіцієнти, а ridge — ні? Достатньо геометричного пояснення.
5. Що конкретно псує кодування категорій, виконане до розбиття на фолди, і чому знак похибки оцінки завжди один і той самий?
6. Ви отримали RMSE 0,13 у логарифмі ціни. Що це число означає в доларах для будинку за 150 тисяч і для будинку за 500 тисяч?
7. Випадкове розбиття дало кращу оцінку, ніж розбиття за датою. Що саме модель дізналася з майбутнього і чому гнучкіша модель виграє від цього більше?