

Лабораторна робота №2. Класифікація, ціна помилки та ансамблі дерев

25 серпня 2026 р.

Мета

Пройти шлях від імовірного походження функції втрат до працездатного класифікатора на двох реальних наборах — діагностичному Breast Cancer Wisconsin і пасажирському Titanic — та довести числами, що якість класифікації визначає не одна метрика, а трійка «поріг, ціна помилки, склад класів».

Теоретичні відомості

Класифікатор повертає не мітку, а ймовірність належності до класу; перетворення ймовірності на рішення — окремий крок, який задає поріг. Саме тому дві моделі з однаковою ROC-AUC можуть бути придатною і непридатною для конкретної задачі: усе вирішує ціна помилки.

- **Логістична регресія.** Лінійна комбінація ознак пропускається крізь сигмоїду $\sigma(z) = 1/(1 + e^{-z})$ і дає ймовірність класу. Функція втрат — перехресна ентропія — походить із принципу максимальної правдоподібності для розподілу Бернуллі, а не обирається довільно. На лінійно розділних даних без регуляризації норма ваг розбігається до нескінченності.
- **Метрики й поріг.** Правильність (ассигасу) оманлива при дисбалансі класів. Матриця похибок розкладає відповіді на чотири типи, звідки походять влучність (precision) і повнота (recall). ROC-крива описує модель на всіх порогах одразу, крива «влучність–повнота» інформативніша при сильному дисбалансі, а сам поріг обирають за ціною помилки.
- **Дерева рішень.** Дерево ділить простір ознак послідовними питаннями про одну ознаку, не потребує масштабування й читається людиною.

Плата — висока дисперсія: зміна кількох зразків може дати зовсім інше дерево.

- **Ансамблі.** Бегінг (випадковий ліс) усереднює багато глибоких дерев, навчених на бутстреп-вибірках, і знижує переважно дисперсію. Бустинг будує дерева послідовно, кожне виправляє помилки попередніх, і знижує переважно зміщення. Звідси різні рекомендації щодо глибини дерев у цих методах.

Корисні посилання для ознайомлення:

- [scikit-learn: Metrics and scoring](#) — усі метрики класифікації з формулами;
- [Post-hoc tuning of the cut-off point](#) — підбір порога під ціну помилки;
- [Permutation feature importance](#) — чому вбудована важливість дерев вводить в оману;
- [Molnar C. Interpretable Machine Learning](#) — книга у відкритому доступі про інтерпретацію моделей.

Порядок виконання

1. Створити віртуальне оточення та встановити `numpy`, `pandas`, `scikit-learn`, `matplotlib`, `seaborn`. Зафіксувати `random_state` в усіх розбиттях і моделях.
2. Завантажити Breast Cancer Wisconsin (`load_breast_cancer`): 569 зразків, 30 ознак, 212 злоякісних і 357 доброякісних пухлин. Першою ж дією надрукувати `target_names` поруч із розподілом `target` і явно зафіксувати у звіті, який клас вважається позитивним.
3. Реалізувати логістичну регресію з нуля: сигмоїда, перехресна ентропія з множником $1/N$ та її аналітичний градієнт. Перевірити градієнт скінченними різницями і навести максимальну розбіжність. Навчити модель і звірити ваги з `LogisticRegression`.
4. Зробити стратифіковане розбиття (`stratify=y`), за порогом 0,5 побудувати матрицю похибок і навести правильність, влучність, повноту та F1. Побудувати ROC-криву й криву «влучність–повнота», навести обидві площі під кривими.
5. Прийняти, що пропуск злоякісної пухлини коштує у 20 разів дорожче за хибну тривогу. Обчислити очікувану вартість на цільній сітці порогів, знайти оптимальний поріг і порівняти його з 0,5. Навести, як змінюються матриця похибок і сумарна вартість.

6. Завантажити Titanic (`seaborn.load_dataset('titanic')`): 891 запис, 549 загиблих і 342 врятованих. Побудувати теплову карту пропусків і свідомо вирішити долю стовпця `deck` (688 порожніх значень із 891). Зібрати конвеєр із заповненням пропусків і кодуванням категорій.
7. Навчити дерево рішень, підібрати `max_depth` серед значень від 1 до 12 за крос-валідацією й показати криву валідації цілком. Візуалізувати дерево обмеженої глибини та простежити шлях одного конкретного пасажера по його вузлах.
8. Порівняти на обох наборах чотири моделі на тих самих фолдах: регуляризовану логістичну регресію, одне дерево, випадковий ліс із 300 дерев і градієнтний бустинг. Навести таблицю метрик і час навчання.
9. Порівняти три оцінки важливості ознак на Breast Cancer: вбудовану `feature_importances_` випадкового лісу, перестановочну важливість на відкладеній вибірці та коефіцієнти логістичної регресії на стандартизованих ознаках. Пояснити розбіжності, звернувши увагу на скорельовані ознаки.
10. Звести метрики всіх моделей обох наборів в одну таблицю, явно вказавши позитивний клас і поріг, за яким отримано кожен результат. Зробити висновки щодо вибору моделі для кожної із двох задач.

Контрольні запитання

1. Чому квадратичні втрати непридатні для класифікації навіть тоді, коли мітки записані числами 0 і 1?
2. Що відбувається з нормою ваг логістичної регресії без регуляризації на лінійно розділних даних, і чому це проблема оптимізації, а не статистики?
3. Модель має правильність 0,97 на вибірці, де 3 % позитивних. Що ще потрібно знати, перш ніж обговорювати цей результат?
4. Ви змінили поріг з 0,5 на 0,05. Які показники зміняться, а які залишаться тими самими, і чому?
5. Чому бегінг знижує переважно дисперсію, а бустинг — переважно зміщення? Що з цього впливає для глибини дерев у кожному методі?
6. Дві ознаки скорельовані на рівні 0,98. Що покаже вбудована важливість випадкового лісу, що — перестановочна, і як отримати чесну відповідь?