

Лабораторна робота №2.

Класифікація за сильного дисбалансу: шахрайство та відтік клієнтів

26 серпня 2026 р.

Мета

Пройти шлях від імовірнісного походження функції втрат до працездатного класифікатора на двох реальних наборах — банківських транзакціях із рідкісним шахрайством і клієнтах телеком-оператора — та довести числами, що за такого дисбалансу правильність не означає нічого, ROC-крива вводиться в оману, а поріг вирішує все.

Теоретичні відомості

Класифікатор повертає не мітку, а ймовірність; перетворення ймовірності на рішення — окремий крок. За частки позитивного класу 0,17% модель, яка завжди відповідає «все гаразд», має правильність 99,83% і не знаходить жодного шахрайства. Саме тому ця робота починається не з моделі, а з вибору метрики.

- **Логістична регресія.** Лінійна комбінація ознак пропускається крізь сигмоїду й дає ймовірність класу. Функція втрат — перехресна ентропія — походить із максимальної правдоподібності для розподілу Бернуллі, а не обирається довільно.
- **Метрики за дисбалансу.** Матриця похибок розкладає відповіді на чотири типи, звідки походять влучність і повнота. ROC-крива описує модель на всіх порогах, але за частки позитивних 0,17% вона виглядає майже ідеальною навіть у поганій моделі: хибнопозитивна частка ділиться на 284 тисячі негативних і лишається мізерною. Крива «влучність–повнота» такого ефекту не має, тому саме її беруть за орієнтир.
- **Поріг і ціна помилки.** Пропущене шахрайство коштує суми транзакції, хибна тривога — дзвінка оператора. Якщо обидві величини виразити числом, оптимальний поріг обчислюється, а не вгадується.
- **Дерева й ансамблі.** Дерево ділить простір послідовними питаннями, не потребує масштабування й читається людиною, але має високу дисперсію. Бегінг (випадковий ліс) усереднює багато глибоких дерев і знижує дисперсію; бустинг будує дерева послідовно, кожне виправляє помилки попередніх, і знижує зміщення. Обидва разом із зваженням класів — стандартний інструмент за дисбалансу.

Корисні посилання для ознайомлення:

- [Credit Card Fraud Detection на OpenML](#) — 284 807 транзакцій європейських карток за два дні вересня 2013 року; ознаки V1–V28 — головні компоненти, оприлюднені замість вихідних даних із міркувань приватності;

- [Telco Customer Churn на OpenML](#) — 7043 клієнти, 17 категоріальних ознак, відтік 26,5 %;
- [Saito T., Rehmsmeier M. The Precision-Recall Plot Is More Informative than the ROC Plot](#) — симуляції, які показують, коли ROC вводять в оману;
- [scikit-learn: Post-hoc tuning of the cut-off point](#) — підбір порога під ціну помилки;
- [Permutation feature importance](#) — чому вбудована важливість дерев вводять в оману.

Порядок виконання

1. Завантажити набір транзакцій Credit Card Fraud і показати масштаб дисбалансу класів графічно та числом.
2. Реалізувати логістичну регресію з нуля, перевірити градієнт скінченними різницями й звірити результат із бібліотечною реалізацією.
3. Порівняти якість моделі з якістю тривіального класифікатора, який завжди відповідає «не шахрайство». Пояснити, що з цього випливає для вибору метрики.
4. Побудувати ROC-криву та криву «влучність–повнота» на тих самих передбаченнях і пояснити, чому вони дають різне враження про модель.
5. Задати ціну помилки кожного типу числом і обчислити оптимальний поріг. Показати, як змінюються матриця похибок і сумарна вартість порівняно з порогом 0,5.
6. Порівняти щонайменше три способи роботи з дисбалансом на тих самих фолдах і пояснити, чому перевибірку не можна робити до розбиття.
7. На наборі Telco Customer Churn навчити дерево рішень і два ансамблі, підібравши глибину дерева за крос-валідацією. Сформулювати знайдене деревом правило звичайною мовою.
8. Порівняти щонайменше дві оцінки важливості ознак і пояснити розбіжність між ними. Звести метрики всіх моделей обох наборів в одну таблицю, вказавши позитивний клас і поріг.

Контрольні запитання

1. Модель має правильність 99,8 % на транзакціях. Чому це число не говорить ні про що, і яка пара метрик його замінює?
2. Чому за частки позитивного класу 0,17 % ROC-крива виглядає майже ідеальною навіть у поганої моделі? Спирайтеся на означення хибнопозитивної частки.
3. Ви змінили поріг з 0,5 на 0,01. Які показники зміняться, а які залишаться тими самими, і чому?
4. Перевибірку рідкісного класу зроблено до розбиття на фолди. Опишіть механізм виток та його вплив на оцінку.
5. Чому бегінг знижує переважно дисперсію, а бустинг — переважно зміщення? Що з цього випливає для глибини дерев у кожному методі?
6. Дві ознаки скорельовані на рівні 0,98. Що покаже вбудована важливість випадкового лісу, що — перестановочна, і як отримати чесну відповідь?