

Лабораторна робота №2. Класифікація за сильного дисбалансу: шахрайство та відтік клієнтів

25 серпня 2026 р.

Мета

Пройти шлях від імовірного походження функції втрат до працездатного класифікатора на двох реальних наборах — 284 807 транзакцій із часткою шахрайських 0,17 % і 7043 клієнтів телеком-оператора з відтоком 26,5 % — та довести числами, що за такого дисбалансу правильність не означає нічого, ROC-крива вводять в оману, а поріг вирішує все.

Теоретичні відомості

Класифікатор повертає не мітку, а ймовірність; перетворення ймовірності на рішення — окремий крок. За частки позитивного класу 0,17 % модель, яка завжди відповідає «все гаразд», має правильність 99,83 % і не знаходить жодного шахрайства. Саме тому ця робота починається не з моделі, а з вибору метрики.

- **Логістична регресія.** Лінійна комбінація ознак пропускається крізь сигмоїду й дає ймовірність класу. Функція втрат — перехресна ентропія — походить із максимальної правдоподібності для розподілу Бернуллі, а не обирається довільно.
- **Метрики за дисбалансу.** Матриця похибок розкладає відповіді на чотири типи, звідки походять влучність і повнота. ROC-крива описує модель на всіх порогах, але за частки позитивних 0,17 % вона виглядає майже ідеальною навіть у поганій моделі: хибнопозитивна частка ділиться на 284 тисячі негативних і лишається мізерною. Крива «влучність–повнота» такого ефекту не має, тому саме її беруть за орієнтир.
- **Поріг і ціна помилки.** Пропущене шахрайство коштує суми транзакції, хибна тривога — дзвінка оператора. Якщо обидві величини виразити числом, оптимальний поріг обчислюється, а не вгадується.

- **Дерева й ансамблі.** Дерево ділить простір послідовними питаннями, не потребує масштабування й читається людиною, але має високу дисперсію. Бегінг (випадковий ліс) усереднює багато глибоких дерев і знижує дисперсію; бустинг будує дерева послідовно, кожне виправляє помилки попередніх, і знижує зміщення. Обидва разом із зваженням класів — стандартний інструмент за дисбалансу.

Корисні посилання для ознайомлення:

- [Credit Card Fraud Detection на OpenML](#) — 284 807 транзакцій європейських карток за два дні вересня 2013 року; ознаки V1–V28 — головні компоненти, оприлюднені замість вихідних даних із міркувань приватності;
- [Telco Customer Churn на OpenML](#) — 7043 клієнти, 17 категоріальних ознак, відтік 26,5 %;
- [Saito T., Rehmsmeier M. The Precision-Recall Plot Is More Informative than the ROC Plot](#) — симуляції, які показують, коли ROC вводить в оману;
- [scikit-learn: Post-hoc tuning of the cut-off point](#) — підбір порога під ціну помилки;
- [Permutation feature importance](#) — чому вбудована важливість дерев вводить в оману.

Порядок виконання

1. Створити оточення та встановити `numpy`, `pandas`, `scikit-learn`, `matplotlib`, `seaborn`. Зафіксувати `random_state` в усіх розбиттях і моделях.
2. Завантажити набір транзакцій: `fetch_openml(data_id=1597, as_frame=True)`. Підтвердити розміри й частку шахрайств. Побудувати розподіл суми транзакції окремо для двох класів у логарифмічній шкалі та розподіл за часом доби.
3. Реалізувати логістичну регресію з нуля: сигмоїда, перехресна ентропія з множником $1/N$ та її аналітичний градієнт. Перевірити градієнт скінченними різницями. Навчити на підвибірці й звірити ваги з `LogisticRegression`.
4. Зробити стратифіковане розбиття. За порогом 0,5 побудувати матрицю похибок і навести правильність, влучність, повноту та F1. Окремо навести правильність моделі, яка завжди відповідає «не шахрайство», і порівняти обидва числа.

5. Побудувати ROC-криву й криву «влучність–повнота» на тих самих передбаченнях, навести обидві площі. Пояснити, чому ROC-AUC виглядає високою, а середня влучність — ні, спираючись на кількість негативних прикладів.
6. Прийняти, що пропущене шахрайство коштує суми транзакції, а хибна тривога — 3 умовні одиниці. Обчислити сумарну вартість на щільній сітці порогів, знайти оптимальний і порівняти його з 0,5. Навести, як змінюються матриця похибок і сумарна вартість.
7. Порівняти три способи боротьби з дисбалансом на тих самих фолдах: `class_weight="balanced"`, випадкове зменшення більшого класу та `RandomForestClassifier` зі зваженням. Показати, що дає кожен за середньою влучністю, і пояснити, чому перевибірку не можна робити до розбиття на фолди.
8. Завантажити набір про відтік: `fetch_openml(data_id=42178, as_frame=True)`. Побудувати теплову карту пропусків, зібрати конвеєр із кодуванням 17 категоріальних ознак. Навчити дерево рішень, підібрати `max_depth` за крос-валідацією й показати криву валідації цілком.
9. Візуалізувати дерево обмеженої глибини та простежити шлях одного конкретного клієнта по його вузлах. Сформулювати правило, яке дерево знайшло, звичайною мовою.
10. Порівняти на обох наборах чотири моделі на тих самих фолдах: регуляризовану логістичну регресію, одне дерево, випадковий ліс і градієнтний бустинг. Навести таблицю метрик і час навчання.
11. Порівняти три оцінки важливості ознак на наборі про відтік: вбудовану `feature_importances_`, перестановочну важливість на відкладений вибірці та коефіцієнти логістичної регресії. Пояснити розбіжності, звернувши увагу на скорельовані ознаки.
12. Звести метрики всіх моделей обох наборів в одну таблицю, явно вказавши позитивний клас і поріг. Для кожного набору назвати метрику, за якою робився вибір, і обґрунтувати її.

Контрольні запитання

1. Модель має правильність 99,8 % на транзакціях. Чому це число не говорить ні про що, і яка пара метрик його замінює?
2. Чому за частки позитивного класу 0,17 % ROC-крива виглядає майже ідеальною навіть у поганій моделі? Спірайтеся на означення хибно-позитивної частки.
3. Ви змінили поріг з 0,5 на 0,01. Які показники зміняться, а які залишаться тими самими, і чому?

4. Перевибірку рідкісного класу зроблено до розбиття на фолди. Опишіть механізм витоку та його вплив на оцінку.
5. Чому бегінг знижує переважно дисперсію, а бустинг — переважно зміщення? Що з цього впливає для глибини дерев у кожному методі?
6. Дві ознаки скорельовані на рівні 0,98. Що покаже вбудована важливість випадкового лісу, що — перестановочна, і як отримати чесну відповідь?