

Лабораторна робота №2.

Класифікація за сильного дисбалансу: шахрайство та банківський телемаркетинг

5 вересня 2026 р.

Мета

Пройти шлях від імовірнісного походження функції втрат до працездатного класифікатора на двох реальних наборах — банківських транзакціях із рідкісним шахрайством і записах телефонної кампанії португальського банку — та довести числами, що за такого дисбалансу правильність не означає нічого, ROC-крива вводять в оману, а поріг вирішує все. Друга частина роботи додає до дисбалансу ще дві біди, з якими стикається кожна реальна задача: ознаку, значення якої стає відомим лише після події, і зміну самого розподілу даних із часом.

Теоретичні відомості

Класифікатор повертає не мітку, а ймовірність; перетворення ймовірності на рішення — окремий крок. За частки позитивного класу 0,17 % модель, яка завжди відповідає «все гаразд», має правильність 99,83 % і не знаходить жодного шахрайства. Саме тому ця робота починається не з моделі, а з вибору метрики.

- **Логістична регресія.** Лінійна комбінація ознак пропускається крізь сигмоїду й дає ймовірність класу. Функція втрат — перехресна ентропія — походить із максимальної правдоподібності для розподілу Бернуллі, а не обирається довільно.
- **Метрики за дисбалансу.** Матриця похибок розкладає відповіді на чотири типи, звідки походять влучність і повнота. ROC-крива описує модель на всіх порогах, але за частки позитивних 0,17 % вона виглядає майже ідеальною навіть у поганій моделі: хибнопозитивна частка ділиться на 284 тисячі негативних і лишається мізерною. Крива «влучність–повнота» такого ефекту не має, тому саме її беруть за орієнтир.
- **Поріг і ціна помилки.** Пропущене шахрайство коштує суми транзакції, хибна тривога — дзвінка оператора. Якщо обидві величини виразити числом, оптимальний поріг обчислюється, а не вгадується.
- **Ознака, відома лише постфактум.** Тривалість розмови з клієнтом чудово передбачає згоду — але дізнатися її можна тільки після того, як розмову завершено, тобто після настання події, яку ми нібито передбачаємо. Автори набору попереджають про це прямо в описі. Така ознака не є витоком у сенсі ЛОЗ (її не підглянули з тестової вибірки), проте робить модель непридатною: у момент, коли рішення справді треба ухвалити, значення ознаки не існує. Перевірка проста — запитати про кожну ознаку, чи була б вона відома до моменту прогнозу.

- **Зсув розподілу з часом.** Дані телефонної кампанії зібрано з травня 2008 до листопада 2010 року, і рядки в наборі впорядковані за часом. Частка згод за цей період зросла з 5,05 % до 51,60 %: банк поступово змінював і список тих, кому телефонують, і саму пропозицію. Модель, навчена на ранньому періоді, працює на пізньому гірше, ніж обіцяє випадкова крос-валідація, — і побачити це можна лише розбиттям за часом.
- **Дерева й ансамблі.** Дерево ділить простір послідовними питаннями, не потребує масштабування й читається людиною, але має високу дисперсію. Бегінг (випадковий ліс) усереднює багато глибоких дерев і знижує дисперсію; бустинг будує дерева послідовно, кожне виправляє помилки попередніх, і знижує зміщення. Обидва разом із зваженням класів — стандартний інструмент за дисбалансу.

Корисні посилання для ознайомлення:

- [Credit Card Fraud Detection на OpenML](#) — 284 807 транзакцій європейських карток за два дні вересня 2013 року; ознаки V1–V28 — головні компоненти, оприлюднені замість вихідних даних із міркувань приватності;
- [Bank Marketing на OpenML](#) — 45 211 дзвінків португальського банку, 16 ознак, з яких 9 категоріальних; частка згод 11,7 %. Столпці в цій копії знеособлено до V1–V16, тому перед роботою їх треба перейменувати за словником із UCI (порядок збережено);
- [Bank Marketing в репозиторії UCI](#) — словник ознак і застереження авторів про `duration`;
- [Moro S., Cortez P., Rita P. A Data-Driven Approach to Predict the Success of Bank Telemarketing](#) (Decision Support Systems, 2014) — стаття, для якої зібрано набір;
- [Saito T., Rehmsmeier M. The Precision-Recall Plot Is More Informative than the ROC Plot](#) — симуляції, які показують, коли ROC вводять в оману;
- [scikit-learn: Post-hoc tuning of the cut-off point](#) — підбір порога під ціну помилки;
- [Permutation feature importance](#) — чому вбудована важливість дерев вводять в оману.

Порядок виконання

1. Завантажити набір транзакцій Credit Card Fraud і показати масштаб дисбалансу класів графічно та числом.
2. Реалізувати логістичну регресію з нуля, перевірити градієнт скінченними різницями й звірити результат із бібліотечною реалізацією.
3. Порівняти якість моделі з якістю тривіального класифікатора, який завжди відповідає «не шахрайство». Пояснити, що з цього випливає для вибору метрики.
4. Побудувати ROC-криву та криву «влучність–повнота» на тих самих передбаченнях і пояснити, чому вони дають різне враження про модель.
5. Задати ціну помилки кожного типу числом і обчислити оптимальний поріг. Показати, як змінюються матриця похибок і сумарна вартість порівняно з порогом 0,5.
6. Порівняти щонайменше три способи роботи з дисбалансом на тих самих фолдах і пояснити, чому перевибірку не можна робити до розбиття.
7. Завантажити набір Bank Marketing, перейменувати столпці за словником UCI і показати, як частка згод змінюється від 2008 до 2010 року. Межі років визначити за столпцем `month`: рядки впорядковані за часом, тож рік змінюється там, де номер місяця зменшується.

8. Навчити дерево рішень і два ансамблі, підібравши глибину дерева за крос-валідацією. Сформулювати знайдене деревом правило звичайною мовою. Категоріальні ознаки закодувати всередині конвеєра, а не до розбиття.
9. Виміряти обидві пастки числом на кривій «влучність–повнота». Порівняти чотири варіанти: випадкове розбиття проти розбиття за часом (навчання на 2008 році, перевірка на 2009–2010) і повний набір ознак проти набору без **duration**. Оскільки базова частка позитивного класу в цих двох тестових вибірках різна, порівнювати треба не саму площу під кривою, а її перевагу над базовим рівнем, що дорівнює частці позитивного класу. Пояснити, який із чотирьох варіантів має право потрапити у звіт замовникові й чому.
10. Порівняти щонайменше дві оцінки важливості ознак і пояснити розбіжність між ними. Звести метрики всіх моделей обох наборів в одну таблицю, вказавши позитивний клас, поріг і спосіб розбиття.

Контрольні запитання

1. Модель має правильність 99,8 % на транзакціях. Чому це число не говорить ні про що, і яка пара метрик його замінює?
2. Чому за частки позитивного класу 0,17 % ROC-крива виглядає майже ідеальною навіть у поганій моделі? Спирайтеся на означення хибнопозитивної частки.
3. Ви змінили поріг з 0,5 на 0,01. Які показники зміняться, а які залишаться тими самими, і чому?
4. Перевибірку рідкісного класу зроблено до розбиття на фолди. Опишіть механізм витоку та його вплив на оцінку.
5. Чому бегінг знижує переважно дисперсію, а бустинг — переважно зміщення? Що з цього впливає для глибини дерев у кожному методі?
6. Дві ознаки скорельовані на рівні 0,98. Що покаже вбудована важливість випадкового лісу, що — перестановочна, і як отримати чесну відповідь?
7. Ознака **duration** не потрапляє в модель із тестової вибірки й не порушує золотого правила з Л03 — проте користуватися нею не можна. Сформулюйте, чим цей випадок відрізняється від витоку даних, і назвіть питання, яке відсіює обидва.
8. Частка згод у наборі зросла з 5 % до 52 %. Поясніть, чому за такої зміни випадкова крос-валідація дає завищену оцінку, і що саме вона змішує між навчальною й перевіркою частинами.