

Лабораторна робота №3.

Ядрові методи, кластеризація та зниження розмірності на сигналах смартфона

26 серпня 2026 р.

Мета

Опанувати три сюжети на межі навчання з учителем і без нього на наборі, де висока розмірність справжня, а не навчальна: записи акселерометра й гіроскопа смартфона, сотні ознак, кілька видів фізичної активності. Побудувати опорно-векторний класифікатор із ядром, знайти структуру без міток і звести 561 вимір до двох, чесно оцінивши, що при цьому втрачається.

Теоретичні відомості

Три теми об'єднує поняття відстані: SVM шукає межу з максимальним відступом, кластеризація групує близькі об'єкти, зниження розмірності зберігає взаємні відстані. На 561 ознаці стає видно те, чого не видно на двовимірних прикладах: у високій розмірності відстані втрачають контрастність, і від цього страждають усі три методи.

- **Опорно-векторна машина.** Серед усіх роздільних гіперплощин обирається та, що має найбільший відступ. Максимізація відступу еквівалентна мінімізації $\|\mathbf{w}\|^2$ за умов $y_n(\mathbf{x}_n^\top \mathbf{w} + b) \geq 1$. Розв'язок залежить лише від опорних векторів; решту даних можна видалити без зміни результату.
- **Ядровий трюк.** Замість явного переходу в простір вищої розмірності обчислюють ядро $K(\mathbf{x}, \mathbf{x}') = \varphi(\mathbf{x})^\top \varphi(\mathbf{x}')$ безпосередньо. Параметр γ гаусового ядра задає радіус впливу точки, C — ціну порушення відступу; підбирати їх треба спільно.
- **Прокляття розмірності.** Зі зростанням кількості ознак контраст відстаней падає: на десяти ознаках цього набору відношення найбільшої попарної відстані до найменшої дорівнює приблизно 1500, на 561 — уже близько 13. Точки не стають однаково далекими буквально (ознаки скорельовані, тому ефект слабший, ніж на незалежному шумі), але різниця між «близько» і «далеко» стискається на два порядки — і саме на ній тримаються методи, що спираються на відстань.
- **Кластеризація.** k -середніх знаходить лише опуклі згустки приблизно однакового розміру. DBSCAN будує кластери за щільністю, знаходить довільні форми й окремо позначає шум. Ієрархічна кластеризація дає дендрограму — усі рівні розбиття одразу.
- **Зниження розмірності.** PCA шукає ортогональні напрями максимальної дисперсії; це лінійний метод. t-SNE зберігає локальні сусідства ціною глобальної геометрії: відстані між згустками на його карті інтерпретувати не можна.

Корисні посилання для ознайомлення:

- [Human Activity Recognition Using Smartphones на OpenML](#) — набір вантажиться викликом `fetch_openml(data_id=1478)`;
- [Опис набору в UCI](#) — як саме отримано 561 ознаку з трьох осей акселерометра й гіроскопа;
- [scikit-learn: Support Vector Machines](#) — документація з поясненням C і γ ;
- [scikit-learn: Clustering](#) — порівняльна таблиця алгоритмів та їхніх припущень;
- [How to Use t-SNE Effectively \(Distill\)](#) — інтерактивна стаття про те, які висновки з карти t-SNE робити не можна.

Порядок виконання

1. Завантажити набір Human Activity Recognition і провести первинний огляд: походження ознак, розподіл класів.
2. Показати експериментально, як зі зростанням кількості ознак падає контраст відстаней. Пояснити наслідки для методів, що спираються на відстань.
3. Побудувати опорно-векторний класифікатор із лінійним ядром, підбравши C за крос-валідацією щонайменше на восьми значеннях. Навести кількість опорних векторів.
4. Підібрати C і γ гаусового ядра спільно, сіткою щонайменше 6×6 . Результат показати тепловою картою й порівняти з лінійною моделлю.
5. Кластеризувати дані без міток, обравши кількість кластерів обґрунтовано. Порівняти розбиття зі справжніми активностями й пояснити, які з них алгоритм об'єднав і чому.
6. Застосувати щільнісну кластеризацію до тих самих даних і пояснити, чому за такої розмірності вона працює гірше, ніж на двовимірних прикладах.
7. Звести дані до двох вимірів лінійним і нелінійним методом, розфарбувавши точки за активностями. Сформулювати, що на цих картах інтерпретувати можна, а що — ні.
8. Порівняти класифікатор на повному наборі ознак і на головних компонентах за якістю та часом. Звести всі обрані гіперпараметри в одну таблицю з обґрунтуванням.

Контрольні запитання

1. Що станеться з розв'язком SVM, якщо видалити точку, яка не є опорним вектором, і чому?
2. У чому саме полягає економія ядрового трюку, якщо простір ознак гаусового ядра нескінченновимірний?
3. Контраст відстаней на 561 ознаці впав на два порядки проти десяти ознак. Які методи з цієї роботи від цього страждають найбільше і чому?
4. Чому кількість кластерів у k -середніх не можна обрати крос-валідацією?
5. Кластеризація об'єднала «ходьбу вгору» і «ходьбу вниз» в один кластер, хоча це різні класи. Це помилка алгоритму чи ні?
6. PCA застосовано без стандартизації. Що покаже перша компонента на цих даних і чому?

7. Ви бачите на карті t-SNE два згустки, розділені великим проміжком. Що з цього випливає, а що — ні?