

Лабораторна робота №3.

Ядрові методи, кластеризація та зниження розмірності

25 серпня 2026 р.

Мета

Опанувати три сюжети на межі навчання з учителем і без нього: побудувати опорно-векторний класифікатор із лінійним і гаусовим ядром, розділити ті самі дані трьома різними алгоритмами кластеризації та звести розмірність, чесно оцінивши, що при цьому втрачається.

Теоретичні відомості

Об'єднує ці три теми поняття відстані: SVM шукає межу з максимальним відступом, кластеризація групує близькі об'єкти, а зниження розмірності зберігає взаємні відстані в меншому просторі. Спільний наслідок — усі три методи критично залежать від масштабу ознак.

- **Опорно-векторна машина.** Серед усіх роздільних гіперплощин обирається та, що має найбільший відступ до найближчих точок. Максимізація відступу еквівалентна мінімізації $\|\mathbf{w}\|^2$ за умов $y_n(\mathbf{x}_n^\top \mathbf{w} + b) \geq 1$. Розв'язок залежить лише від опорних векторів — точок на межі відступу; решту даних можна видалити без зміни результату.
- **Ядровий трюк.** Замість явного переходу в простір вищої розмірності обчислюють ядро $K(\mathbf{x}, \mathbf{x}') = \varphi(\mathbf{x})^\top \varphi(\mathbf{x}')$ безпосередньо. Гаусове ядро $\exp(-\gamma\|\mathbf{x} - \mathbf{x}'\|^2)$ відповідає нескінченновимірному простору, але коштує одного обчислення відстані. Параметр γ задає радіус впливу точки, C — ціну порушення відступу; підбирати їх треба спільно.
- **Кластеризація.** k -середніх мінімізує суму квадратів відстаней до центроїдів і тому знаходить лише опуклі згустки приблизно однакового розміру. DBSCAN будує кластери за щільністю, знаходить довільні форми й окремо позначає шум. Ієрархічна кластеризація дає дендрограму — усі рівні розбиття одразу.

- **Зниження розмірності.** PCA шукає ортогональні напрями максимальної дисперсії; це лінійний метод, і на нестандартизованих даних першу компоненту забирає ознака з найбільшим розмахом. t-SNE зберігає локальні сусідства ціною глобальної геометрії: відстані між згустками на його карті інтерпретувати не можна.

Корисні посилання для ознайомлення:

- [scikit-learn: Support Vector Machines](#) — документація з поясненням C і γ ;
- [scikit-learn: Clustering](#) — порівняльна таблиця всіх алгоритмів та їхніх припущень;
- [How to Use t-SNE Effectively \(Distill\)](#) — інтерактивна стаття про те, які висновки з карти t-SNE робити не можна;
- [Cornell CS4780: Kernels](#) — конспект лекції про ядровий трюк.

Порядок виконання

1. Створити віртуальне оточення та встановити `numpy`, `pandas`, `scikit-learn`, `scipy`, `matplotlib`. Зафіксувати `random_state` у всіх розбиттях і алгоритмах.
2. Завантажити Wine (`load_wine`): 178 зразків, 13 ознак, три сорти (59, 71 і 48 зразків). Навести таблицю описових статистик і порівняти розмахи ознак `proline` та `magnesium` — це визначить необхідність масштабування.
3. Підібрати C для лінійної SVM на логарифмічній сітці щонайменше з 8 значень за 5-блочною крос-валідацією. Побудувати криву валідації двічі — на масштабованих і немасштабованих ознаках — і навести кількість опорних векторів для найкращої моделі.
4. Згенерувати `make_moons` і `make_circles` по 300 точок із `noise=0.25`. Порівняти лінійну та RBF-SVM за межами рішень, а не лише за точністю: побудувати межі через `DecisionBoundaryDisplay` для обох наборів і обох ядер.
5. Виконати спільний підбір C і γ через `GridSearchCV` на сітці щонайменше 6×6 у логарифмічній шкалі. Зобразити результат тепловою картою й пояснити форму області високої якості.
6. Прибрати мітки Wine і кластеризувати стандартизовані дані для k від 2 до 10 по 10 перезапусків. Побудувати графік внутрішньокластерної суми квадратів і середнього силуету; обрати k і обґрунтувати вибір, не використовуючи справжні мітки.

7. Порівняти обраний розподіл із справжніми сортами через `adjusted_rand_score` і таблицю спряженості. Пояснити, чому збіг кластерів із класами не є ані обов'язковим, ані критерієм якості кластеризації.
8. На `make_moons` обрати ϵ для DBSCAN за зломом графіка відстані до 4-го сусіда, запустити алгоритм і навести частку точок, позначених як шум. Побудувати дендрограму ієрархічної кластеризації тих самих даних і порівняти три результати.
9. Виконати PCA на Wine двічі — на стандартизованих і нестандартизованих ознаках — і порівняти навантаження першої компоненти. Побудувати стовпчикову діаграму власних значень і кумулятивну криву поясненої дисперсії; указати найменше K , що пояснює 90 % дисперсії.
10. Побудувати вкладення `load_digits` методом t-SNE для перплексій 5, 30, 50 і 100, по два різні `random_state` на кожну. Показати, що змінюється між запусками, і сформулювати, які висновки з таких карт робити коректно.
11. Звести всі обрані гіперпараметри (C , `gamma`, k , ϵ , K) в одну таблицю з коротким обґрунтуванням кожного вибору.

Контрольні запитання

1. Що станеться з розв'язком SVM, якщо видалити точку, яка не є опорним вектором, і чому?
2. У чому саме полягає економія ядрового трюку, якщо простір ознак гаусового ядра нескінченновимірний?
3. Що геометрично робить збільшення `gamma` і як це видно на межі рішень?
4. Чому кількість кластерів у k -середніх не можна обрати крос-валідацією?
5. Які кластери k -середніх принципово не здатний знайти і яка властивість алгоритму це спричиняє?
6. PCA застосовано до Wine без стандартизації. Що покаже перша компонента і чому?
7. Ви бачите на карті t-SNE два згустки, розділені великим проміжком. Що з цього впливає, а що — ні?