

Лабораторна робота №3.

Ядрові методи, кластеризація та зниження розмірності на сигналах смартфона

25 серпня 2026 р.

Мета

Опанувати три сюжети на межі навчання з учителем і без нього на наборі, де висока розмірність справжня, а не навчальна: 10 299 записів акселерометра й гіроскопа смартфона, 561 ознака, шість видів фізичної активності. Побудувати опорно-векторний класифікатор із ядром, знайти структуру без міток і звести 561 вимір до двох, чесно оцінивши, що при цьому втрачається.

Теоретичні відомості

Три теми об'єднує поняття відстані: SVM шукає межу з максимальним відступом, кластеризація групує близькі об'єкти, зниження розмірності зберігає взаємні відстані. На 561 ознаці стає видно те, чого не видно на двовимірних прикладах: у високій розмірності відстані втрачають контрастність, і від цього страждають усі три методи.

- **Опорно-векторна машина.** Серед усіх роздільних гіперплощин обирається та, що має найбільший відступ. Максимізація відступу еквівалентна мінімізації $\|\mathbf{w}\|^2$ за умов $y_n(\mathbf{x}_n^\top \mathbf{w} + b) \geq 1$. Розв'язок залежить лише від опорних векторів; решту даних можна видалити без зміни результату.
- **Ядровий трюк.** Замість явного переходу в простір вищої розмірності обчислюють ядро $K(\mathbf{x}, \mathbf{x}') = \varphi(\mathbf{x})^\top \varphi(\mathbf{x}')$ безпосередньо. Параметр γ гаусового ядра задає радіус впливу точки, C — ціну порушення відступу; підбирати їх треба спільно.
- **Прокляття розмірності.** Зі зростанням кількості ознак контраст відстаней падає: на десяти ознаках цього набору відношення найвищої попарної відстані до найменшої дорівнює приблизно 1500, на 561

— уже близько 13. Точки не стають однаково далекими буквально (ознаки скорельовані, тому ефект слабший, ніж на незалежному шумі), але різниця між «близько» і «далеко» стискається на два порядки — і саме на ній тримаються методи, що спираються на відстань.

- **Кластеризація.** k -середніх знаходить лише опуклі згустки приблизно однакового розміру. DBSCAN будує кластери за щільністю, знаходить довільні форми й окремо позначає шум. Ієрархічна кластеризація дає дендрограму — усі рівні розбиття одразу.
- **Зниження розмірності.** PCA шукає ортогональні напрями максимальної дисперсії; це лінійний метод. t-SNE зберігає локальні сусідства ціною глобальної геометрії: відстані між згустками на його карті інтерпретувати не можна.

Корисні посилання для ознайомлення:

- [Human Activity Recognition Using Smartphones на OpenML](#) — набір вантажиться викликом `fetch_openml(data_id=1478)`;
- [Опис набору в UCI](#) — як саме отримано 561 ознаку з трьох осей акселерометра й гіроскопа;
- [scikit-learn: Support Vector Machines](#) — документація з поясненням C і γ ;
- [scikit-learn: Clustering](#) — порівняльна таблиця алгоритмів та їхніх припущень;
- [How to Use t-SNE Effectively \(Distill\)](#) — інтерактивна стаття про те, які висновки з карти t-SNE робити не можна.

Порядок виконання

1. Створити оточення та встановити `numpy`, `pandas`, `scikit-learn`, `scipy`, `matplotlib`. Зафіксувати `random_state` у всіх розбиттях і алгоритмах.
2. Завантажити набір: `fetch_openml(data_id=1478, as_frame=True)`. Підтвердити розміри (10 299 записів, 561 ознака, 6 класів) і навести розподіл класів. Знайти в описі набору, які саме величини стоять за назвами ознак, і навести приклади трьох різних груп.
3. Показати прокляття розмірності на цих даних: для випадкових 500 записів побудувати гістограму попарних евклідових відстаней на 10, 50, 200 і всіх 561 стандартизованих ознаці. Навести відношення найбільшої відстані до найменшої в кожному випадку (має вийти спадна послідовність приблизно від 1500 до 13) і пояснити, що з цього випливає для методу найближчих сусідів. Окремо пояснити, чому падіння сповільнюється: ознаки цього набору сильно скорельовані, тому справжня розмірність даних менша за 561.

4. Підібрати C для лінійної SVM на логарифмічній сітці щонайменше з 8 значень за 5-блочною крос-валідацією. Навести криву валідації та кількість опорних векторів для найкращої моделі; порівняти цю кількість із розміром навчальної вибірки.
5. Виконати спільний підбір C і γ для гаусового ядра через `GridSearchCV` на сітці щонайменше 6×6 . Зобразити результат тепловою картою й пояснити форму області високої якості. Порівняти найкращі лінійну й ядрову моделі за точністю та часом навчання.
6. Побудувати матрицю похибок найкращої моделі. Знайти пару класів, які плутаються найчастіше, і пояснити, чому саме вони: подивитися на назви відповідних активностей.
7. Прибрати мітки й кластеризувати стандартизовані дані k -середніми для k від 2 до 10, по 10 перезапусків. Побудувати графік внутрішньокластерної суми квадратів і середнього силуету; обрати k і обґрунтувати вибір, не використовуючи справжні мітки.
8. Порівняти отримане розбиття зі справжніми активностями через `adjusted_rand_score` і таблицю спряженості. Пояснити, які активності алгоритм об'єднав в один кластер і чому це осмислено з фізичного погляду.
9. Запустити DBSCAN на тих самих даних, обравши ϵ за зламом графіка відстані до 4-го сусіда. Навести частку точок, позначених як шум, і пояснити, чому за такої розмірності метод працює гірше, ніж на двовимірних прикладах.
10. Виконати PCA двічі — на стандартизованих і нестандартизованих ознаках — і порівняти частку поясненої дисперсії першої компоненти. Побудувати кумулятивну криву та вказати найменше K , що пояснює 90 % дисперсії. Порівняти це число з 561.
11. Побудувати двовимірні вкладки PCA і t-SNE, розфарбувавши точки за справжніми активностями. Для t-SNE взяти перплексії 5, 30 і 50, по два різні `random_state` на кожну. Сформулювати, що на цих картах можна інтерпретувати, а що — ні.
12. Навчити лінійну SVM на K головних компонентах замість 561 ознаки й порівняти з моделлю на повному наборі за точністю та часом. Звести всі обрані гіперпараметри (C , γ , k , ϵ , K) в одну таблицю з обґрунтуванням.

Контрольні запитання

1. Що станеться з розв'язком SVM, якщо видалити точку, яка не є опорним вектором, і чому?

2. У чому саме полягає економія ядрового трюку, якщо простір ознак гаусового ядра нескінченновимірний?
3. Контраст відстаней на 561 ознаці впав на два порядки проти десяти ознак. Які методи з цієї роботи від цього страждають найбільше і чому?
4. Чому кількість кластерів у k -середніх не можна обрати крос-валідацією?
5. Кластеризація об'єднала «ходьбу вгору» і «ходьбу вниз» в один кластер, хоча це різні класи. Це помилка алгоритму чи ні?
6. PCA застосовано без стандартизації. Що покаже перша компонента на цих даних і чому?
7. Ви бачите на карті t-SNE два згустки, розділені великим проміжком. Що з цього випливає, а що — ні?