

Лабораторна робота №3.

Ядрові методи, кластеризація та зниження розмірності на сигналах смартфона й газових сенсорів

6 вересня 2026 р.

Мета

Опанувати три сюжети на межі навчання з учителем і без нього на наборі, де висока розмірність справжня, а не навчальна: записи акселерометра й гіроскопа смартфона, сотні ознак, кілька видів фізичної активності. Побудувати опорно-векторний класифікатор із ядром, знайти структуру без міток і звести 561 вимір до двох, чесно оцінивши, що при цьому втрачається. Наприкінці — перевірити ті самі методи на другому наборі, де прилад повільно змінюється з часом, і виміряти, скільки коштує ця зміна.

Теоретичні відомості

Три теми об'єднують поняття відстані: SVM шукає межу з максимальним відступом, кластеризація групує близькі об'єкти, зниження розмірності зберігає взаємні відстані. На 561 ознаці стає видно те, чого не видно на двовимірних прикладах: у високій розмірності відстані втрачають контрастність, і від цього страждають усі три методи.

- **Опорно-векторна машина.** Серед усіх роздільних гіперплощин обирається та, що має найбільший відступ. Максимізація відступу еквівалентна мінімізації $\|\mathbf{w}\|^2$ за умов $y_n(\mathbf{x}_n^\top \mathbf{w} + b) \geq 1$. Розв'язок залежить лише від опорних векторів; решту даних можна видалити без зміни результату.
- **Ядровий трюк.** Замість явного переходу в простір вищої розмірності обчислюють ядро $K(\mathbf{x}, \mathbf{x}') = \varphi(\mathbf{x})^\top \varphi(\mathbf{x}')$ безпосередньо. Параметр γ гаусового ядра задає радіус впливу точки, C — ціну порушення відступу; підбирати їх треба спільно.
- **Зсув розподілу в часі.** Другий набір роботи — показання шістнадцяти газових сенсорів, зібрані десятками партіями протягом 36 місяців. Сенсори повільно старіють і забруднюються, тож те саме значення на виході приладу через два роки означає вже іншу концентрацію. Формально це зсув розподілу ознак: $p(x)$ змінюється, а залежність $p(y \mid x)$, яку вивчила модель, лишається старою. Виявляється це лише тоді, коли перевірені дані зібрано пізніше за навчальні, — випадкове перемішування партій приховує проблему повністю.
- **Прокляття розмірності.** Зі зростанням кількості ознак контраст відстаней падає: на десяти ознаках цього набору відношення найбільшої попарної відстані до найменшої дорівнює приблизно 1500, на 561 — уже близько 13. Точки не стають однаково далекими буквально (ознаки скорельовані, тому ефект слабший, ніж на незалежному шумі), але різниця між «близько» і «далеко» стискається на два порядки — і саме на ній тримаються методи, що спираються на відстані.

- **Кластеризація.** k -середніх знаходить лише опуклі згустки приблизно однакового розміру. DBSCAN будує кластери за щільністю, знаходить довільні форми й окремо позначає шум. Ієрархічна кластеризація дає дендрограму — усі рівні розбиття одразу.
- **Зниження розмірності.** PCA шукає ортогональні напрями максимальної дисперсії; це лінійний метод. t-SNE зберігає локальні сусідства ціною глобальної геометрії: відстані між згустками на його карті інтерпретувати не можна.

Корисні посилання для ознайомлення:

- [Human Activity Recognition Using Smartphones на OpenML](#) — набір вантажиться викликом `fetch_openml(data_id=1478)`;
- [Gas Sensor Array Drift Dataset](#) — 13 910 вимірів по 128 ознак, розкладені по десяти партіях; беріть саме архів UCI (близько 10 МБ, файли `batch1.dat`–`batch10.dat` у форматі `libsvm`), бо в копії на OpenML номерів партій немає, а без них головний дослід неможливий;
- [Опис набору в UCI](#) — як саме отримано 561 ознаку з трьох осей акселерометра й гіроскопа;
- [scikit-learn: Support Vector Machines](#) — документація з поясненням C і γ ;
- [scikit-learn: Clustering](#) — порівняльна таблиця алгоритмів та їхніх припущень;
- [How to Use t-SNE Effectively \(Distill\)](#) — інтерактивна стаття про те, які висновки з карти t-SNE робити не можна.

Порядок виконання

1. Завантажити набір Human Activity Recognition і провести первинний огляд: походження ознак, розподіл класів.
2. Показати експериментально, як зі зростанням кількості ознак падає контраст відстаней. Пояснити наслідки для методів, що спираються на відстань.
3. Побудувати опорно-векторний класифікатор із лінійним ядром, підбравши C за крос-валідацією щонайменше на восьми значеннях. Навести кількість опорних векторів.
4. Підібрати C і γ гаусового ядра спільно, сіткою щонайменше 6×6 . Результат показати тепловою картою й порівняти з лінійною моделлю.
5. Кластеризувати дані без міток, обравши кількість кластерів обґрунтовано. Порівняти розбиття зі справжніми активностями й пояснити, які з них алгоритм об'єднав і чому.
6. Застосувати щільнісну кластеризацію до тих самих даних і пояснити, чому за такої розмірності вона працює гірше, ніж на двовимірних прикладах.
7. Звести дані до двох вимірів лінійним і нелінійним методом, розфарбувавши точки за активностями. Сформулювати, що на цих картах інтерпретувати можна, а що — ні.
8. Порівняти класифікатор на повному наборі ознак і на головних компонентах за якістю та часом. Звести всі обрані гіперпараметри в одну таблицю з обґрунтуванням.
9. Перейти до набору газових сенсорів. Навчити ядрову SVM на першій партії та перевірити її по черзі на партіях 2–10, побудувавши графік точності від номера партії. Поруч навести перехресну перевірку всередині першої партії.
10. На тому самому наборі порівняти два способи розбиття: навчання на партіях 1–9 з перевіркою на партії 10 та випадкове розбиття тих самих об'єднаних даних у тій самій пропорції. Пояснити різницю й сказати, яка з двох оцінок є чесним прогнозом якості на наступному році роботи приладу.

Контрольні запитання

1. Що станеться з розв'язком SVM, якщо видалити точку, яка не є опорним вектором, і чому?
2. У чому саме полягає економія ядрового трюку, якщо простір ознак гаусового ядра нескінченновимірний?
3. Контраст відстаней на 561 ознаці впав на два порядки проти десяти ознак. Які методи з цієї роботи від цього страждають найбільше і чому?
4. Чому кількість кластерів у k -середніх не можна обрати крос-валідацією?
5. Кластеризація об'єднала «ходьбу вгору» і «ходьбу вниз» в один кластер, хоча це різні класи. Це помилка алгоритму чи ні?
6. PCA застосовано без стандартизації. Що покаже перша компонента на цих даних і чому?
7. Ви бачите на карті t-SNE два згустки, розділені великим проміжком. Що з цього випливає, а що — ні?
8. Модель на газових сенсорах дала 0,99 за випадкового розбиття й помітно менше, коли перевіркою стала остання партія. Обидва числа пораховано правильно. Яке з них ви покажете замовникові й чому саме воно?
9. Назвіть два способи зменшити падіння якості з часом на такому приладі — один із боку даних, другий із боку моделі — і скажіть, чого жоден із них не гарантує.