

Лабораторна робота №5.

Механізм уваги, подання даних і генеративна модель

25 серпня 2026 р.

Мета

Зібрати механізм уваги власноруч — від масштабованого скалярного добутку до багатоголової самоуваги — і застосувати його до реальних даних як мініатюрний трансформер; далі виміряти, наскільки вивчені подання кращі за сирі пікселі, побудувати варіаційний автокодувальник із картою латентного простору й перевірити стійкість класифікатора до змагальних збурень.

Теоретичні відомості

Три сюжети цієї роботи об'єднує одна ідея: корисне подання даних важливіше за конкретний класифікатор поверх нього. Увага будує подання з урахуванням контексту, автокодувальник — стискаючи дані до кількох чисел, змагальні приклади показують, наскільки крихкими ці подання бувають.

- **Масштабований скалярний добуток.** $\text{Attention}(Q, K, V) = \text{softmax}(QK^\top / \sqrt{d_k}) V$.
Ділення на $\sqrt{d_k}$ не косметичне: без нього при великій розмірності оцінки розходяться за модулем, softmax насичується й градієнт зникає. Багатоголовий варіант виконує кілька таких операцій паралельно у підпросторах і склеює результати.
- **Позиційне кодування.** Самоувага симетрична щодо перестановки входів, тому без позиційної інформації речення з переставленими словами дають однаковий результат. Синусоїдальне кодування додається до вкладень і має властивість: скалярний добуток двох кодувань залежить лише від відстані між позиціями.
- **Варіаційний автокодувальник.** Кодувальник видає параметри розподілу (μ, σ^2) , а не точку; репараметризація $z = \mu + \sigma \epsilon$ дозволяє пропустити градієнт крізь випадковість. Втрати — сума реконструкції та

розходження Кульбака–Лейблера; без другого доданка модель вироджується у звичайний автокодувальник і породжувати не вміє.

- **Змагальні приклади.** Атака FGSM робить один крок уздовж знаку градієнта *за входом*: $\hat{x} = x + \varepsilon \text{sign}(\nabla_x \mathcal{L})$. Збурення, непомітне для ока, змінює відповідь мережі — отже, твердження «модель стійка» не має сенсу без указаної норми та бюджету ε .

Корисні посилання для ознайомлення:

- [Vaswani та ін. Attention Is All You Need](#) — оригінальна стаття у PDF;
- [The Annotated Transformer](#) — та сама стаття у вигляді працездатного ноутбука;
- [The Illustrated Transformer](#) — візуальне пояснення кожного кроку;
- [Kingma D., Welling M. Auto-Encoding Variational Bayes](#) — оригінальна стаття про VAE;
- [CleverHans](#) — еталонні реалізації змагальних атак.

Порядок виконання

1. Створити оточення та встановити `torch`, `torchvision`, `numpy`, `scikit-learn`, `matplotlib`, `seaborn`. Зафіксувати зерна генераторів у всіх експериментах.
2. Реалізувати масштабований скалярний добуток на NumPy і звірити результат із `torch.nn.functional.scaled_dot_product_attention`. Окремо показати експериментально, що станеться з розподілом ваг уваги при $d_k = 256$, якщо не ділити оцінки на $\sqrt{d_k}$.
3. Зібрати багатоголову самоувагу з H головами й вихідною проекцією W_O ; перенести ті самі ваги в `torch.nn.MultiheadAttention` і довести збіг виходів. Звернути увагу на порядок осей: помилка тут найпоширеніша.
4. Розбити зображення MNIST 28×28 на 16 патчів 7×7 , лінійно вкласти їх у розмірність $D = 64$, додати позиційні вкладення й навчити мініатюрний трансформер класифікувати цифри. Перевірити розбиття візуально, зібравши зображення назад із патчів.
5. Порівняти два подання тих самих 5000 тестових зображень: сирі пікселі (784 виміри) та вихід останнього блока трансформера. Класифікатор найближчих сусідів навчити на обох просторах за однакових умов і навести обидві точності.

6. Реалізувати VAE для MNIST: кодувальник $784 \rightarrow 400 \rightarrow (\mu, \sigma^2)$, латентна розмірність 2, симетричний декодувальник. Втрати — бінарна перехресна ентропія плюс доданок Кульбака–Лейблера; вивести обидва доданки окремо на кожній епосі.
7. Побудувати карту латентного простору: сітку точок z пропустити крізь декодувальник і показати сітку згенерованих цифр. Пояснити, за що відповідає доданок Кульбака–Лейблера, спираючись на виведені окремо значення обох доданків.
8. Реалізувати атаку FGSM із градієнтом за входом і побудувати криву точності класифікатора з пункту 4 від бюджету ϵ щонайменше на п'яти значеннях. Показати приклади зображень до і після атаки з підписаними передбаченнями.
9. Пояснити на числах із попереднього пункту, що означає «модель стійка до збурень» і чому це твердження не має сенсу без указаної норми та бюджету ϵ .
10. Звести результати у три таблиці однакового формату: моделей, подань і стійкості. Зробити висновки про те, які подання виявилися кращими й чому.

Додаткові завдання (необов'язкові)

Ці пункти виходять за межі аудиторного часу й виконуються за бажанням; вони не впливають на основну оцінку, але зараховуються як бонус.

1. Додати до порівняння з пункту 5 третє подання — вкладення патчів після першого лінійного шару — і пояснити, чому воно опиняється між сирими пікселями та виходом трансформера.
2. Навчити звичайний автокодувальник тієї самої архітектури й порівняти з VAE при генерації з випадкового z : що саме ламається без доданка Кульбака–Лейблера.
3. Провести змагальне тренування класифікатора з $\epsilon = 0,1$ і навести таблицю «звичайна точність — точність під атакою» до і після. Показати, якою є ціна стійкості.

Контрольні запитання

1. Що станеться з розподілом ваг уваги при $d_k = 256$, якщо не ділити оцінки на $\sqrt{d_k}$?
2. Чому самоувага без позиційних вкладень дає однаковий результат для речень із переставленими словами?

3. Що саме зміщує самоувага, а що — багатошаровий перцептрон усередині блоку трансформера?
4. Навіщо у варіаційному автокодувальнику потрібна репараметризація і що зламається без неї?
5. Ви прибрати з функції втрат доданок Кульбака–Лейблера. Що станеться з реконструкціями, а що — з генерацією?
6. Градієнт у змагальній атаці береться за входом, а не за вагами. Чому це принципово і як його порахувати наявними засобами?
7. Що означає твердження «модель стійка до збурень» без указаної норми та бюджету ε ?