

Лабораторна робота №5.

Механізм уваги на текстах і генеративна модель

2 вересня 2026 р.

Мета

Зібрати механізм уваги власноруч — від масштабованого скалярного добутку до багатоголової самоуваги — і застосувати його до справжніх текстів: класифікувати повідомлення з архіву 20 Newsgroups. Далі виміряти, наскільки вивчені подання кращі за мішок слів, побудувати варіаційний автокодувальник на Fashion-MNIST і перевірити стійкість класифікатора до змагальних збурень.

Теоретичні відомості

Роботу об'єднує одна ідея: корисне подання даних важливіше за конкретний класифікатор поверх нього. Увага будує подання з урахуванням контексту, автокодувальник — стискаючи дані до кількох чисел, змагальні приклади показують, наскільки крихкими ці подання бувають. На текстах це видно найкраще: те саме слово в різних повідомленнях означає різне.

- **Масштабований скалярний добуток.** $\text{Attention}(Q, K, V) = \text{softmax}(QK^\top / \sqrt{d_k}) V$. Ділення на $\sqrt{d_k}$ не косметичне: без нього при великій розмірності оцінки розходяться за модулем, softmax насичується й градієнт зникає.
- **Позиційне кодування.** Самоувага симетрична щодо перестановки входів, тому без позиційної інформації речення з переставленими словами дають однаковий результат. На текстах це перевіряється безпосередньо: досить переставити слова у вхідній послідовності й порівняти виходи.
- **Мішок слів проти контексту.** TF-IDF дає кожному слову один вектор незалежно від речення. Самоувага будує подання слова з урахуванням сусідів, тому «bank» у фінансовому й географічному контексті отримує різні вектори. Різницю треба виміряти, а не приймати на віру.
- **Варіаційний автокодувальник.** Кодувальник видає параметри розподілу (μ, σ^2) , а не точку; репараметризація $z = \mu + \sigma \epsilon$ дозволяє пропустити градієнт крізь випадковість. Втрати — сума реконструкції та розходження Кульбака–Лейблера; без другого доданка модель вироджується у звичайний автокодувальник.
- **Змагальні приклади.** Атака FGSM робить один крок уздовж знаку градієнта *за входом*: $\hat{x} = x + \epsilon \text{sign}(\nabla_x \mathcal{L})$. Збурення, непомітне для ока, змінює відповідь мережі — отже, твердження «модель стійка» не має сенсу без указаної норми та бюджету ϵ .

Корисні посилання для ознайомлення:

- [20 Newsgroups](#) — 18 846 повідомлень із 20 тематичних груп; вантажиться викликом `fetch_20newsgroups`;

- [Fashion-MNIST](#) — 70 000 зображень одягу 28×28 ; складніший за рукописні цифри, але навчається так само швидко;
- [Vaswani та ін. Attention Is All You Need](#) — оригінальна стаття у PDF;
- [The Annotated Transformer](#) — та сама стаття у вигляді працездатного ноутбука;
- [Kingma D., Welling M. Auto-Encoding Variational Bayes](#) — оригінальна стаття про VAE;
- [CleverHans](#) — еталонні реалізації змагальних атак.

Порядок виконання

1. Завантажити кілька тематичних груп із 20 Newsgroups і побудувати базову лінію на мішку слів. Навести точність на тесті.
2. Реалізувати масштабований скалярний добуток самостійно й звірити з бібліотечною функцією. Показати експериментально, навіщо потрібне масштабування оцінок.
3. Зібрати багатоголову самоувагу й довести збіг її виходів із бібліотечною реалізацією.
4. Побудувати мініатюрний трансформер для класифікації текстів і порівняти його з базовою лінією.
5. Перевірити потребу в позиційних вкладеннях прямим експериментом і пояснити отриману різницю.
6. Порівняти якість двох подань тих самих текстів — мішка слів і виходу трансформера — класифікатором найближчих сусідів за однакових умов.
7. Реалізувати варіаційний автокодувальник на Fashion-MNIST, вивівши обидва доданки функції втрат окремо. Побудувати карту латентного простору.
8. Реалізувати атаку одним кроком за градієнтом за входом і побудувати криву точності від бюджету збурення щонайменше на п'яти значеннях. Звести результати у таблиці й зробити висновки, які подання виявилися кращими та за яку ціну.

Додаткові завдання (необов'язкові)

Ці пункти виходять за межі аудиторного часу й виконуються за бажанням; вони не впливають на основну оцінку, але зараховуються як бонус.

1. Додати до порівняння з пункту 6 третє подання — усереднені вектори GloVe — і пояснити, чому воно опиняється між TF-IDF та виходом трансформера.
2. Навчити звичайний автокодувальник тієї самої архітектури й порівняти з VAE при генерації з випадкового z : що саме ламається без доданка Кульбака–Лейблера.
3. Провести змагальне тренування класифікатора з $\varepsilon = 0,1$ і навести таблицю «звичайна точність — точність під атакою» до і після. Показати, якою є ціна стійкості.

Контрольні запитання

1. Що станеться з розподілом ваг уваги при $d_k = 256$, якщо не ділити оцінки на $\sqrt{d_k}$?
2. Ви переставили слова у вхідному тексті. Чому модель без позиційних вкладень дала той самий результат, а з ними — інший?
3. Що саме змішує самоувага, а що — багатошаровий перцептрон усередині блоку трансформера?
4. Чому TF-IDF дає слову один вектор незалежно від речення, і в яких задачах цього достатньо?
5. Навіщо у варіаційному автокодувальнику потрібна репараметризація і що зламається без неї?
6. Ви прибрали з функції втрат доданок Кульбака–Лейблера. Що станеться з реконструкціями, а що — з генерацією?
7. Що означає твердження «модель стійка до збурень» без указаної норми та бюджету ε ?